

SERVICE ACTUEL · MCP-SERVER-CORPUS

Outils MCP de recherche de corpus

4 capacités analysées

services/mcp-server-corpus · Python/FastMCP, aiohttp, Pydantic et OpenTelemetry.

Offrir découverte et recherche documentaire autorisées aux agents sans dupliquer le backend RAG.

Lecture de code Pas de qualification runtime nouvelle

Domaines cible : MCP, AI, Embeddings, IAM, Audit.

Périmètre de lecture

- Analyses existantes 11-ml-embeddings et 14-front-api reprises comme contexte ; vérifications ciblées des routes, outils et implémentations citées ci-dessous.
- Instructions racine et AGENTS.md du composant lorsqu'il existe ; aucun binaire propriétaire inspecté.
- Lecture statique ciblée pour finalisation ; les branches non exécutées et le déploiement restent non qualifiés.

Objets et cycle de vie

- CorpusListResult et CorpusSearchResult ; mandat de lecture et scope par requête.

Dépendances du service

- ai-gen-assistant public/interne ; cleyrop_common.mcp_read ; IAM via délégation.

Fonctionnalités et compatibilité à préserver

MCP-01 Cible non qualifiée

Découvrir les corpus accessibles dans le périmètre de l'agent

COMPORTEMENT OBSERVÉ

list_corpora_tool appelle l'API de corpus pour l'utilisateur courant, puis filtre selon les noms techniques imposés au contexte MCP. Le résultat contient UUID, nom, description, nombre de documents et total ; des erreurs structurées distinguent refus d'accès et défaillance.

UTILISATEURS ET RÔLES

Agents MCP et utilisateurs RAG.

INTERFACES DANS LE CODE

MCP list_corpora_tool.

DONNÉES ET ÉTATS

Résultat de découverte éphémère, sans catalogue local autoritaire.

DÉPENDANCES ET ÉCHANGES

API publique ai-gen-assistant et mandat de lecture.

COMPORTEMENT CIBLE PROPOSÉ

MCP Rust expose uniquement les corpus autorisés et épinglés ; Catalog/Embeddings restent les autorités.

MIGRATION DE CETTE CAPACITÉ

Conserver schéma et noms des outils ; remplacer le backend par un adaptateur aux éditions publiées.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Un contexte limité à A ne voit ni nom ni total de B ; IAM indisponible ne devient pas une liste complète.

Références de l'analyse

[monorepo](#) · [services/mcp-server-corpus/src/tool/corpus_searcher.py:226](#) Découverte et filtrage du périmètre.

MCPC-02 Cible non qualifiée

Chercher sémantiquement dans un ou plusieurs corpus

COMPORTEMENT OBSERVÉ

L'outil accepte une question et des noms techniques. Le scope de contexte remplace l'argument du modèle. Il résout les noms en UUID parmi les corpus accessibles, refuse les inconnus puis appelle search_corpora. Sans sélection, il cherche dans les corpus accessibles. Le résultat contient documents et métadonnées ; les champs de texte sont nettoyés des caractères invisibles et espaces exotiques.

UTILISATEURS ET RÔLES

Agents et utilisateurs qui interrogent leurs connaissances.

INTERFACES DANS LE CODE

MCP corpus_search_tool ; client POST /corpora/search.

DONNÉES ET ÉTATS

Documents retournés, total et erreur ; aucune écriture de vecteurs ici.

DÉPENDANCES ET ÉCHANGES

Backend de recherche assistant, droits IAM et données de corpus.

COMPORTEMENT CIBLE PROPOSÉ

MCP restitue citations, hashes et édition servie ; Embeddings vérifie les droits avant texte et avant envoi au LLM.

MIGRATION DE CETTE CAPACITÉ

Préserver nettoyage et erreurs ; ajouter provenance d'édition et limites de résultats sans inventer un checkpoint dans MCP.

CRITÈRE D'ACCEPTATION À EXÉCUTER

La question ne peut élargir le scope fixé ; une citation reste résoluble sur l'édition lue et disparaît de la restitution après révocation.

Références de l'analyse

[monorepo](#) · [services/mcp-server-corpus/src/tool/corpus_searcher.py:286](#) Résolution de noms et recherche.

[monorepo](#) · [services/mcp-server-corpus/src/tool/corpus_searcher.py:188](#) Normalisation du texte.

MCPC-03 Cible non qualifiée

Propager une identité ou un mandat de lecture délégué

COMPORTEMENT OBSERVÉ

L'identité vient du Bearer entrant. Le client sait aussi porter DelegatedRead, appelle son autorisation et obtient des headers frais pour le backend interne. Les erreurs MCPReadAuthenticationError exposent code et possibilité de retry. La session HTTP partagée désactive la persistance des cookies pour éviter qu'un cookie reçu pour un utilisateur soit renvoyé pour un autre.

UTILISATEURS ET RÔLES

Orchestrateur d'assistant, IAM et utilisateurs.

INTERFACES DANS LE CODE

get_user_access_token ; DelegatedRead ; CorpusApiClient.

DONNÉES ET ÉTATS

Credential par requête, session HTTP mutualisée sans cookies utilisateur.

DÉPENDANCES ET ÉCHANGES

cleyrop_common.mcp_read, API interne et API publique.

COMPORTEMENT CIBLE PROPOSÉ

IAM/MCP Rust émet un mandat court lié au sujet, tenant, ressources et action de lecture ; jamais de credential générique d'écriture.

MIGRATION DE CETTE CAPACITÉ

Qualifier expiration, renouvellement et révocation déléguée ; conserver la différence entre mandat et Bearer direct.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Deux utilisateurs partageant le pool HTTP ne partagent aucune session backend ; un mandat expiré est refusé avant lecture.

Références de l'analyse

[monorepo](#) · [services/mcp-server-corpus/src/utils/user_token.py:17](#) Lecture du Bearer et délégation.

[monorepo](#) · [services/mcp-server-corpus/src/corpus_api/corpus_api_client.py:56](#) Session commune et cookies.

MCPC-04 Cible non qualifiée

Servir MCP HTTP avec progression, erreurs et traces

COMPORTEMENT OBSERVÉ

Le serveur monte les deux outils sur un transport HTTP streamable, fournit /health et instrumente les requêtes ASGI et les appels aiohttp pour propager les traces. Les outils émettent des informations et une progression. Le lifespan ferme la session HTTP ; aucun stockage local durable de recherche n'est montré.

UTILISATEURS ET RÔLES

Clients MCP et opérateurs.

INTERFACES DANS LE CODE

{CONTEXT_PATH}/mcp ; GET /health ; événements progress/info/error.

DONNÉES ET ÉTATS

Sessions et traces de transport.

DÉPENDANCES ET ÉCHANGES

FastMCP, aiohttp et OpenTelemetry.

COMPORTEMENT CIBLE PROPOSÉ

MCP Rust conserve schémas, annulation, progression et corrélation ; la santé distingue process et dépendances.

MIGRATION DE CETTE CAPACITÉ

Tests de protocole MCP avec clients existants, erreurs backend et arrêt en cours d'appel.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Une annulation libère les connexions ; une erreur backend conserve un code stable et les logs n'exposent pas le credential.

Références de l'analyse

[monorepo](#) · [services/mcp-server-corpus/src/server.py:84](#) Fermeture de session.

[monorepo](#) · [services/mcp-server-corpus/src/server.py:128](#) Transport et chemin MCP.

Architecture et exploitation du service cible

Plan de contrôle Rust proposé

- MCP Rust expose uniquement les corpus autorisés et épinglés ; Catalog/Embeddings restent les autorités.
- MCP restitue citations, hashes et édition servie ; Embeddings vérifie les droits avant texte et avant envoi au LLM.
- IAM/MCP Rust émet un mandat court lié au sujet, tenant, ressources et action de lecture ; jamais de credential générique d'écriture.
- MCP Rust conserve schémas, annulation, progression et corrélation ; la santé distingue process et dépendances.

Plan de données proposé

- Recherche en lecture seule et restitution de documents bornée.

Découpage du core Rust

- mcp-corpus, delegated-read et adaptateur Embeddings.

Identité, autorisation et isolation

- Le scope serveur prime l'argument du modèle ; aucune autorité tirée du texte retrouvé.

- Session HTTP sans cookies ; refus d'auth structurés.

Exploitation et reprise

- Service stateless pour les données ; pool HTTP et traces ; tests non exécutés.

Séquence de migration

- Conserver schéma et noms des outils ; remplacer le backend par un adaptateur aux éditions publiées.
- Préserver nettoyage et erreurs ; ajouter provenance d'édition et limites de résultats sans inventer un checkpoint dans MCP.
- Qualifier expiration, renouvellement et révocation déléguée ; conserver la différence entre mandat et Bearer direct.
- Tests de protocole MCP avec clients existants, erreurs backend et arrêt en cours d'appel.

Écarts et décisions encore ouverts

- Le backend doit ajouter une édition explicite ; le résultat actuel seul ne prouve pas un pin stable.

Références de l'analyse

[monorepo](#) · [services/mcp-server-corpus/src/tool/corpus_searcher.py:226](#) Découverte et filtrage du périmètre.

[monorepo](#) · [services/mcp-server-corpus/src/tool/corpus_searcher.py:286](#) Résolution de noms et recherche.

[monorepo](#) · [services/mcp-server-corpus/src/utils/user_token.py:17](#) Lecture du Bearer et délégation.

[monorepo](#) · [services/mcp-server-corpus/src/server.py:84](#) Fermeture de session.