

SERVICE ACTUEL · MCP-SERVER-INTERNET

Outils MCP de recherche internet

4 capacités analysées

services/mcp-server-internet · Python/FastMCP, aiohttp, providers SearXNG/Staan et parsing de pages.

Chercher puis extraire des sources web pour les agents, avec protections de destination et garde de consommation.

Lecture de code Pas de qualification runtime nouvelle

Domaines cible : MCP, Egress, AI, Audit.

Périmètre de lecture

- Analyses existantes 11-ml-embeddings et 14-front-api reprises comme contexte ; vérifications ciblées des routes, outils et implémentations citées ci-dessous.
- Instructions racine et AGENTS.md du composant lorsqu'il existe ; aucun binaire propriétaire inspecté.
- Lecture statique ciblée pour finalisation ; les branches non exécutées et le déploiement restent non qualifiés.

Objets et cycle de vie

- Requête web, résultat de moteur, page extraite et décision de quota.

Dépendances du service

- Fournisseurs externes, DNS/HTTP/TLS et configuration de quota.

Fonctionnalités et compatibilité à préserver

MCPI-01 Cible non qualifiée

Rechercher sur le web avec un fournisseur configurable

COMPORTEMENT OBSERVÉ

L'outil web_researcher_and_scraper reçoit question, nombre de résultats, sites suggérés, catégories, période et langue. Une factory choisit SearXNG ou Staан selon configuration. Le résultat conserve URL, titre, description, contenu, rang, score et erreur. La description de l'outil annonce une borne de dix résultats ; sa compatibilité exacte reste à tester.

UTILISATEURS ET RÔLES

Agents ayant un mandat de recherche externe.

INTERFACES DANS LE CODE

MCP web_researcher_and_scraper.

DONNÉES ET ÉTATS

SearchRequest/SearchResult et résultat agrégé éphémère.

DÉPENDANCES ET ÉCHANGES

SearXNG ou Staan, configuration et réseau.

COMPORTEMENT CIBLE PROPOSÉ

MCP/Egress Rust autorise les fournisseurs, borne budget et sources et conserve des références citables.

MIGRATION DE CETTE CAPACITÉ

Comparer les paramètres supportés par chaque fournisseur ; annoncer les écarts au lieu d'une recherche uniforme supposée.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Même requête conserve ses paramètres et limites ; un fournisseur indisponible retourne une erreur explicite sans inventer des sources.

Références de l'analyse

[monorepo](#) · [services/mcp-server-internet/src/tools/web_researcher.py:76](#) Paramètres et résultat.

[monorepo](#) · [services/mcp-server-internet/src/search/search_provider_factory.py:54](#) Sélection de fournisseur.

MCPI-02 **Cible non qualifiée****Extraire les pages et conserver les succès partiels****COMPORTEMENT OBSERVÉ**

Le pipeline réutilise le texte fourni par le moteur quand il existe ; il scrape seulement les résultats qui en ont besoin, et certains restent à leur snippet. Les extractions sont rassemblées avec leurs erreurs individuelles pour conserver les succès partiels. Le scraper applique robots.txt à chaque redirection et extrait un texte nettoyé. Les sources retournées et modes d'extraction sont journalisés.

UTILISATEURS ET RÔLES

Agents de recherche et opérateurs.

INTERFACES DANS LE CODE

web_scraper ; WebResearcherResult ; SearchResult.needs_scraping.

DONNÉES ET ÉTATS

Contenu, statut, erreur et durée par page.

DÉPENDANCES ET ÉCHANGES

HTTP externe, parsing HTML et règles robots.

COMPORTEMENT CIBLE PROPOSÉ

Egress/MCP Rust fournit extraction bornée et provenance URL/horodatage/hash ; le contenu externe reste non fiable pour les actions de l'agent.

MIGRATION DE CETTE CAPACITÉ

Rejouer pages sans texte, redirections et extraction partielle ; préserver distinction snippet/contenu complet.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Une page bloquée ne fait pas perdre les autres résultats ; la réponse indique les limites de chaque source.

Références de l'analyse

[monorepo](#) · [services/mcp-server-internet/src/tools/web_researcher.py:141](#) Assemblage des pages avec erreurs.

[monorepo](#) · [services/mcp-server-internet/src/scraper/web_scraper.py:108](#) Extraction et robots.

MCPI-03 Cible non qualifiée

Empêcher les téléchargements vers des adresses non publiques

COMPORTEMENT OBSERVÉ

Le guard valide les URL et adresses IP. Un résolveur DNS contrôle les adresses obtenues et remet ces adresses au connecteur, limitant la fenêtre de re-résolution. Les redirections sont suivies manuellement, revalidées à chaque étape et limitées à cinq. Les IP littérales, destinations privées et cas multicast ont des règles explicites. Cette lecture établit des protections présentes, pas une preuve de résistance à tous les scénarios réseau.

UTILISATEURS ET RÔLES

Opérateurs de sécurité et utilisateurs de recherche externe.

INTERFACES DANS LE CODE

PublicAddressResolver ; ensure_public_url ; open_public_url.

DONNÉES ET ÉTATS

Décision de destination par connexion et compteur de redirections.

DÉPENDANCES ET ÉCHANGES

aiohttp, DNS, TLS et guard partagé.

COMPORTEMENT CIBLE PROPOSÉ

Egress Rust centralise la même politique avec quotas octets/temps et contrôle des proxys ; les outils n'obtiennent aucun accès au réseau interne.

MIGRATION DE CETTE CAPACITÉ

Porter le corpus SSRF/DNS/redirection existant et qualifier dans le réseau cible.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Une redirection publique vers une adresse privée ou un résultat DNS mixte est refusé avant téléchargement ; cinq sauts respectent la borne.

Références de l'analyse

[monorepo](#) · [services/mcp-server-internet/src/utils/address_guard.py:104](#) Contrôle des adresses DNS utilisées.

[monorepo](#) · [services/mcp-server-internet/src/utils/address_guard.py:149](#) Validation de chaque redirection.

MCPI-04 Cible non qualifiée

Borner les recherches payantes et exposer leur état

COMPORTEMENT OBSERVÉ

Le quota de recherche est un token bucket en mémoire par pod, avec débit horaire, capacité de burst et horloge monotone. Une exhaustion renvoie un délai de retry. Le code précise que plusieurs replicas multiplient le plafond et qu'un redémarrage réinitialise les compteurs ; ce n'est pas un budget mensuel durable. Le serveur

expose /health et instrumentation de traces.

UTILISATEURS ET RÔLES

Opérateurs et responsables de consommation.

INTERFACES DANS LE CODE

SearchQuotaGuard ; InMemorySearchQuotaGuard.try_consume ; GET /health.

DONNÉES ET ÉTATS

Compteurs locaux et décision allow/deny avec retry_after.

DÉPENDANCES ET ÉCHANGES

Factory de fournisseur, horloge et OpenTelemetry.

COMPORTEMENT CIBLE PROPOSÉ

AI/Egress Rust ajoute une réservation de budget tenant persistante si un plafond global est requis ; garde local conservé pour les bursts.

MIGRATION DE CETTE CAPACITÉ

Fixer politique de coût et cardinalité tenant ; comparer quotas à un et plusieurs replicas avant migration.

CRITÈRE D'ACCEPTATION À EXÉCUTER

Une boucle d'agent est freinée ; un redémarrage n'efface pas le budget global cible et ne divulgue aucun secret de fournisseur.

Références de l'analyse

[monorepo](#) · [services/mcp-server-internet/src/search/in_memory_search_quota_guard.py:25](#) Token bucket et limites par pod.

[monorepo](#) · [services/mcp-server-internet/src/server.py:46](#) Santé du serveur.

Architecture et exploitation du service cible

Plan de contrôle Rust proposé

- MCP/Egress Rust autorise les fournisseurs, borne budget et sources et conserve des références citables.
- Egress/MCP Rust fournit extraction bornée et provenance URL/horodatage/hash ; le contenu externe reste non fiable pour les actions de l'agent.
- Egress Rust centralise la même politique avec quotas octets/temps et contrôle des proxys ; les outils n'obtiennent aucun accès au réseau interne.
- AI/Egress Rust ajoute une réservation de budget tenant persistante si un plafond global est requis ; garde local conservé pour les bursts.

Plan de données proposé

- Recherche et extraction HTTP bornées, sans publication de dataset implicite.

Découpage du core Rust

- `mcp-web-research`, `provider-adapters`, `public-address-guard` et `quota-ledger`.

Identité, autorisation et isolation

- Adresses publiques, guard DNS et redirections explicites ; tests non exécutés.
- Contenu des pages non fiable ; accès externe accordé par mandat et données de prompt minimisées.

Exploitation et reprise

- Quota local par pod, réinitialisé au redémarrage ; traces et health.

Séquence de migration

- Comparer les paramètres supportés par chaque fournisseur ; annoncer les écarts au lieu d'une recherche uniforme supposée.
- Rejouer pages sans texte, redirections et extraction partielle ; préserver distinction snippet/contenu complet.
- Porter le corpus SSRF/DNS/redirection existant et qualifier dans le réseau cible.
- Fixer politique de coût et cardinalité tenant ; comparer quotas à un et plusieurs replicas avant migration.

Écarts et décisions encore ouverts

- Authentification et autorisation d'exposition à confirmer au niveau gateway/deployment ; aucune garantie déduite du seul serveur MCP.
- Les plafonds octets, durées et catégories exactes doivent être qualifiés par fournisseur.

Références de l'analyse

`monorepo` · `services/mcp-server-internet/src/tools/web_researcher.py:76` Paramètres et résultat.

`monorepo` · `services/mcp-server-internet/src/tools/web_researcher.py:141` Assemblage des pages avec erreurs.

`monorepo` · `services/mcp-server-internet/src/utils/address_guard.py:104` Contrôle des adresses DNS utilisées.

`monorepo` · `services/mcp-server-internet/src/search/in_memory_search_quota_guard.py:25` Token bucket et limites par pod.